IUT Grand Ouest Normandie

Département Science des Données

PORTFOLIO DE COMPÉTENCES

Matthias Defretin

Parcours : Visualisation, conception d'outils décisionnels

Années universitaires 2022 – 2026

Table des matières

I Première Année (2021-2022) **2**

II Deuxième Année (2024-2025) **15**

III Troisième Année (2025-2026) **18**

Première partie

Première Année (2021-2022)

SAÉ 1-01 Création de reporting à partir de données stockées dans un SGBD relationnel

A. Présentation du projet

Dans cette SAÉ intitulée « Création de reporting à partir de données stockées dans un SGBD relationnel », nous avons été missionnés par le chef de police de Gotham City pour trouver l'identité de Batman à l'aide de différents fichiers de données et d'une base de données. Suite à cette enquête, le maire de la ville nous a demandé de réaliser des analyses statistiques des habitants afin de mieux connaître son électorat. Nous avons réalisé l'ensemble du travail à l'aide de Python, SQL, R et Excel. C'était une SAÉ qui englobait de nombreux aspects de la formation.

B. Organisation du travail

Pour ce projet, le volume de données était important. Nous nous sommes donc réparti les fichiers à traiter entre les membres du groupe pour les prendre en charge individuellement, puis nous les avons regroupés dans une base de données SQLite. Une fois cette étape terminée, nous avons commencé l'analyse des données ensemble, à l'aide de R et Excel, en examinant différents aspects tels que l'argent, la police et les générations.

C. Démarche de résolution du problème

Pour la première partie de la SAÉ, notre objectif était de trouver l'identité de Batman pour le chef de police, qui nous avait fourni des informations collectées par son équipe. Au départ, un travail important était nécessaire sur le format et l'organisation des données, car certains fichiers étaient très mal structurés. Le nettoyage nous a donc pris un certain temps. Une fois cette étape terminée, l'insertion dans la base de données SQLite ne posait plus de problème. La base étant complète, nous avons pu effectuer des requêtes pour trouver rapidement la véritable identité de Batman. Nous nous sommes ensuite occupés des analyses demandées par le maire et le chef de police. Cette partie a été la plus longue, car nous devions créer de nouvelles données à partir des existantes afin de produire les graphiques appropriés.

D. Conclusion & Acquis

Pour conclure, cette SAÉ a été longue car la partie reporting a pris beaucoup plus de temps que la partie programmation. Cela s'explique peut-être par les facilités que j'ai en Python. Elle m'a néanmoins permis d'approfondir le langage SQL et de découvrir de nouvelles syntaxes pour résoudre les problèmes rencontrés.

SAÉ 1-02 : Écriture et lecture de fichiers de données

A. Présentation du projet

Dans cette SAÉ, notre objectif était d'aider la proviseure d'un lycée à organiser le conseil de classe en triant les données fournies. Ces données provenaient de plusieurs fichiers organisés différemment, notamment des relevés de notes, dans des formats variés (3 fichiers .csv et 3 fichiers .txt). Le tri et le résultat final ont été réalisés à l'aide de Python et de quelques packages.

B. Organisation du travail

Dans ce projet, notre travail consistait à préparer les données de manière à ce qu'elles puissent être exploitées lors d'un conseil de classe. La première étape était de les nettoyer et de les organiser de façon uniforme, afin qu'elles puissent être facilement triées selon les demandes de la cliente. Une fois cette étape réalisée, elle nous a fourni ses instructions spécifiques sur l'organisation souhaitée des fichiers. Il suffisait alors de les ordonner en conséquence, dans l'objectif de rendre les données claires, cohérentes et faciles à interpréter lors du conseil de classe.

C. Démarche de résolution du problème

Nous avons débuté ce projet avec 6 fichiers, chacun organisé différemment. La première étape a été de définir une structure commune pour ranger les données, puis de les récupérer et de les stocker dans une liste de listes en Python. Nous avons ensuite répondu à la demande de la cliente en générant les bulletins de notes pour chaque élève. Les données étant correctement organisées, cette étape n'a pas été très longue. Nous avons utilisé le package `numpy` pour produire une sortie sous forme de fichiers CSV. Cependant, nous avons rencontré quelques difficultés lors de la création des fichiers texte devant correspondre au modèle demandé, ainsi que de petites erreurs résiduelles dans les données après le tri.

D. Conclusion & Acquis

Pour conclure, cette SAÉ est l'une des premières que nous avons réalisées cette année et c'est le type de projet que j'apprécie le plus. Malgré quelques petites difficultés, elle n'a pas été la plus chronophage. La clé était de commencer par élaborer un schéma d'organisation des données : une fois cela fait, il suffisait d'avancer, car nous savions où nous allions. La principale difficulté résidait dans le risque de se perdre lors du tri, ce qui aurait compliqué la suite du projet.

SAÉ 1-03 Préparation et synthèse d'un tableau de données en vue d'une analyse exploratoire simple

A. Présentation du projet

Cette SAÉ a été la toute première de l'année axée sur le langage statistique R. Nous avons reçu un jeu de données sur la location de vélos à New York et notre objectif était d'en réaliser une analyse exploratoire pour le mois de juin 2022.

B. Organisation du travail

Ce projet était un travail de groupe de deux personnes. Comme tout projet, il se divisait en plusieurs étapes : le chargement des données, leur préparation, puis leur analyse.

C. Démarche de résolution du problème

Nous avons commencé par charger les données et les librairies nécessaires, ce qui n'a pas pris beaucoup de temps. Nous avons ensuite vérifié que les données étaient exploitables et dans le bon format, ce qui nous a amenés à la phase de préparation. Cette étape était plus longue, car il fallait être attentif à tout ce qui pourrait poser problème lors de l'analyse. Par exemple, le jeu de données contenait des durées de location négatives qu'il fallait corriger. Une fois les données nettoyées, nous avons pu passer à l'analyse et exploiter les données pour créer des graphiques permettant de faire parler les chiffres sur la location de vélos à New York.

D. Conclusion & Acquis

Pour conclure, cette SAÉ nous a permis de découvrir la programmation statistique avec R. Nous n'avons pas rencontré de difficultés majeures, la SAÉ étant guidée, et nous avons pu trouver rapidement des réponses à nos questions grâce à Internet et à la documentation.

SAÉ 1-04 Apprendre en situation la production de données en entreprise

A. Présentation du projet

Dans cette SAÉ, nous avons réalisé un travail de veille informationnelle et de synthèse sur un sujet spécifique : les mécanismes de production de données en entreprise. Notre objectif était de créer un poster résumant les informations essentielles.

B. Organisation du travail

Le but était de synthétiser des informations pour produire un résultat final clair et organisé. Nous avons commencé par assister à deux cours de deux heures au cours desquels le professeur nous a présenté le sujet. Nous avons ensuite entrepris le travail de synthèse en identifiant les points clés et en les regroupant autour de grands axes, à l'aide d'une carte mentale. Une fois celle-ci terminée, nous avons procédé à la création du poster.

C. Démarche de résolution du problème

La principale difficulté résidait dans la synthèse des informations, car il était difficile de déterminer ce qui devait être inclus ou non. L'objectif était de sélectionner uniquement les éléments essentiels et de les rendre compréhensibles pour n'importe quel lecteur, même sans connaissances préalables dans le domaine. Pour cela, nous avons identifié les points clés et les résultats les plus pertinents, en veillant à utiliser un langage clair et accessible, sans termes techniques complexes.

D. Conclusion

Pour conclure, cette SAÉ m'a permis de développer mes compétences en synthèse afin de produire un contenu compréhensible pour un large public. Cette aptitude est essentielle en contexte professionnel, où tous les interlocuteurs ne sont pas nécessairement familiers avec le sujet traité. Grâce à ce projet, j'ai appris à sélectionner les informations essentielles et à les présenter de manière claire et accessible.

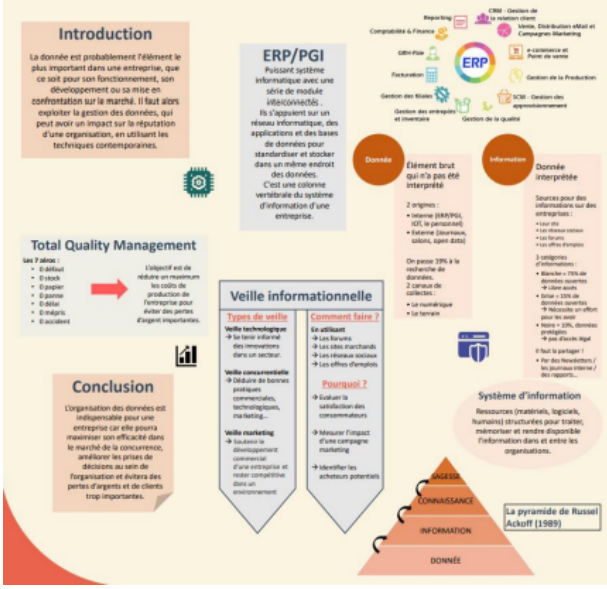

SAÉ 1-05 Présentation en anglais d'un territoire économique et culturel

A. Présentation du projet

Pour cette SAÉ, l'objectif était de rassembler des informations sur un sujet choisi au préalable ici « La différence entre hommes et femmes dans le monde socioprofessionnel normand » afin de les résumer dans un poster, puis d'en faire une présentation orale en anglais.

B. Organisation du travail

Pour ce second projet de synthèse, nous devions rechercher nous-mêmes les informations, en utilisant principalement le site de l'INSEE comme point de départ. Une fois le sujet choisi, nous avons collecté des données pertinentes, puis nous les avons synthétisées de manière claire et concise pour les présenter sur le poster de façon compréhensible et accessible.

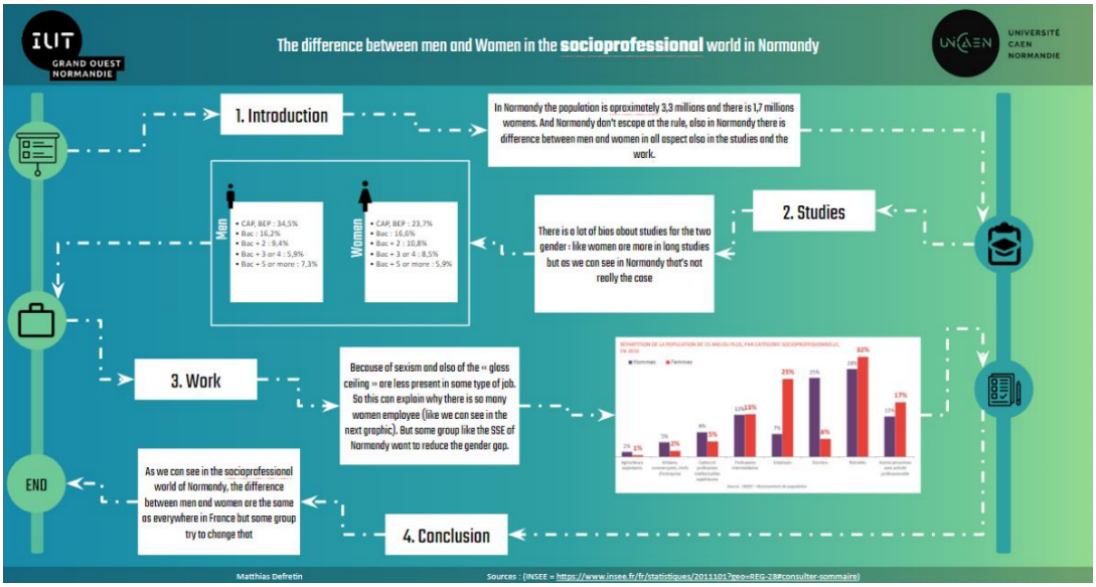

C. Démarche de résolution du problème

La première étape consistait à identifier une problématique, puis à rechercher des données en croisant différentes sources. Une fois une quantité suffisante d'informations rassemblée, il s'agissait de sélectionner l'essentiel, de trouver des illustrations appropriées et de concevoir le poster de manière à le rendre compréhensible pour tous.

D. Conclusion

Pour conclure, ce projet m'a permis de développer mes compétences en synthèse et m'a appris à vérifier la fiabilité des sources. En sélectionnant et en organisant les informations pertinentes, j'ai renforcé mon esprit d'analyse et ma capacité à présenter des résultats de manière concise et accessible.

SAÉ 1-06 Mise en œuvre d'une enquête

A. Présentation du projet

Cette SAÉ avait pour but de nous apprendre à mener une enquête statistique complète, depuis la création d'un questionnaire jusqu'à l'analyse des données collectées. L'ensemble du projet était axé sur le thème des lycéens, et j'ai choisi de me focaliser sur le sujet « Les lycéens et la nourriture ».

B. Organisation du travail

La première partie consistait à créer un questionnaire répondant à un cahier des charges précis, incluant tous les types de questions possibles. Nous aurions ensuite dû nous rendre dans des lycées pour collecter les données, mais en raison des restrictions liées au COVID, cela n'a pas été possible. Nous avons donc utilisé un jeu de données fourni par le Crédit Agricole pour réaliser l'analyse statistique sous R. Comme à l'habitude, celle-ci était divisée en trois étapes : chargement des données, préparation et analyse.

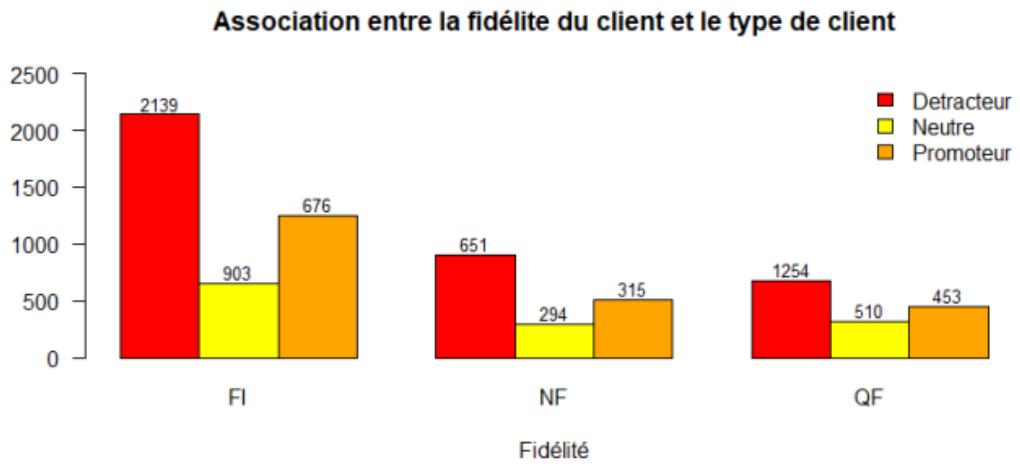

C. Démarche de résolution du problème

La création du questionnaire n'a pas pris beaucoup de temps : il s'agissait principalement de trouver des questions pertinentes et cohérentes avec la problématique. La difficulté principale résidait dans la partie analyse sous R, qui a été plus longue car nous devions trouver par nous-mêmes les représentations graphiques adaptées. Une fois l'analyse terminée, nous avons présenté le projet devant un jury lors d'une soutenance orale.

D. Conclusion

Pour conclure, ce projet m'a permis de comprendre ce que signifie mener une enquête statistique de bout en bout, et d'approfondir une nouvelle fois mes connaissances en R. C'est également la première SAÉ à avoir abouti à une soutenance orale, ce qui m'a permis de découvrir l'exercice de la présentation de projet.

SAÉ 2-01 — Conception et implémentation d'une base de données

A. Présentation du projet

Dans cette SAÉ, nous avions pour mission de concevoir et d'implémenter une base de données locale pour un magasin **Proxi** situé à Wulverdinghe, une petite commune du nord de la France. Suite à une coupure Internet, le magasin ne pouvait plus accéder aux outils de sa centrale parisienne. Il fallait donc développer une solution autonome permettant de maintenir l'activité du commerce. Le projet se déclinait en quatre grandes parties : la conception de la base de données en UML, un outil de gestion du stock en ligne de commande, une interface graphique de caisse, et enfin un dashboard d'analyse des ventes.

B. Organisation du travail

Ce projet a été réalisé en groupe de 5 étudiants. Les rôles ont été répartis selon les compétences de chacun : rédaction du rapport en LaTeX, développement de l'ensemble des outils Python, et participation aux phases de conception. Cette organisation nous a permis de traiter les différentes parties du projet en parallèle.

C. Démarche de résolution du problème

Nous avons commencé par modéliser la base de données en UML, puis nous l'avons implémentée avec SQLite, choisi pour sa légèreté et son fonctionnement hors-ligne. Une table `Stock` centralise les informations sur chaque produit (nom, quantité, emplacement). Ensuite, nous avons développé en Python un outil en ligne de commande proposant quatre fonctionnalités : l'ajout d'un produit au stock, son rangement en rayon, son retrait et sa recherche par code unique. Chaque opération génère un log horodaté pour assurer la traçabilité. Dans un second temps, nous avons complété une interface graphique avec la bibliothèque PyQt5, permettant de saisir le code EAN d'un article pour enregistrer une vente, mettre à jour le stock et générer un ticket de caisse au format TXT. Enfin, nous avons créé un dashboard à l'aide de `Matplotlib` et `Seaborn` pour visualiser les ventes par jour, par mois et par heure.

D. Conclusion & Acquis

Pour conclure, cette SAÉ a été enrichissante car elle couvrait de nombreux aspects vus en formation : la modélisation de bases de données, le développement d'outils Python aussi bien en ligne de commande qu'en interface graphique, et la visualisation de données. Nous avons rencontré quelques difficultés techniques, notamment sur l'affichage chronologique des mois dans le dashboard, mais cela a été une bonne occasion d'apprendre à debugger et à chercher des solutions adaptées.

SAÉ 2-02 Estimation par sondage simple

EN COURS

SAÉ 2-03 Régression sur données réelles

A. Présentation du projet

Dans cette SAÉ, nous avons été chargés de réaliser une analyse statistique afin de déterminer le modèle de régression linéaire le plus approprié à partir d'un jeu de données portant sur l'indice de masse graisseuse, mesuré en pourcentage de la masse corporelle. Notre objectif était d'établir s'il existait une corrélation entre les mesures en centimètres de différentes parties du corps et cet indice.

B. Organisation du travail

Comme à l'habitude, le travail était divisé en trois grandes parties : le chargement des données, leur préparation et leur analyse. Une quatrième étape s'est cependant ajoutée : la modélisation du meilleur modèle de régression linéaire. L'ensemble de la démarche visait à nettoyer les données au maximum afin de déterminer quelle variable serait la plus pertinente pour obtenir un modèle adéquat.

C. Démarche de résolution du problème

La première difficulté rencontrée concernait les valeurs atypiques. Dès les premières représentations graphiques, nous avons remarqué que certaines valeurs s'écartaient nettement de l'intervalle classique, rendant les visualisations inexploitables. La seconde difficulté était liée à la régression linéaire elle-même, qui était une notion nouvelle pour nous à ce stade de la formation et qui a nécessité un temps d'assimilation supplémentaire.

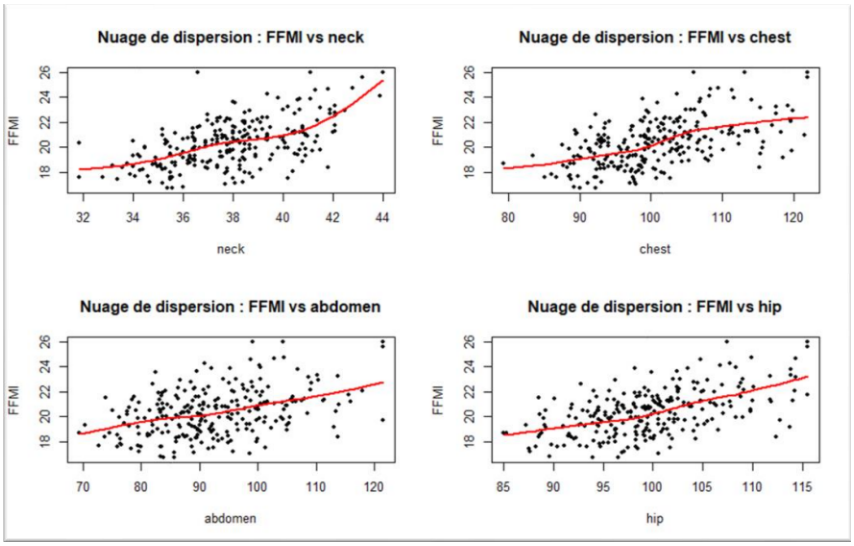

D. Conclusion & Acquis

Pour conclure, cette SAÉ m'a permis d'approfondir mes connaissances en R, en découvrant de nouvelles bibliothèques et fonctionnalités. Elle m'a également aidé à consolider certaines notions statistiques et à découvrir la modélisation par régression linéaire, un outil que je n'avais pas encore eu l'occasion de pratiquer.

SAÉ 2-04 Datavisualisation (challenge)

A. Présentation du projet

Le Challenge DataViz est un concours national organisé chaque année par les départements Science des Données des IUT de France. Les équipes disposent d'une seule journée pour analyser un jeu de données réelles fourni par un partenaire national et produire une visualisation percutante. Pour l'édition 2023, le partenaire était la **SNCF**. Notre équipe de cinq étudiants de l'IUT de Lisieux a remporté la **première place** du concours au niveau local.

B. Organisation du travail

Le format du concours imposait de travailler en autonomie complète sur une journée. Nous avons dû nous organiser rapidement : définir une problématique, répartir les tâches et produire un rendu dans les délais impartis. L'organisation au sein du groupe a été déterminante pour mener à bien l'ensemble des étapes.

C. Démarche de résolution du problème

Notre problématique était : *« L'accessibilité au transport ferroviaire a-t-elle un impact sur les disparités socio-économiques ? »* Nous avons analysé le nombre de départs par type de train (TGV, TER, etc.) par région, croisé avec la médiane du niveau de vie, et intégré ces données dans une **carte dynamique** réalisée sous **Tableau**. Nous avons également produit un classement des sept gares enregistrant le plus grand nombre de départs.

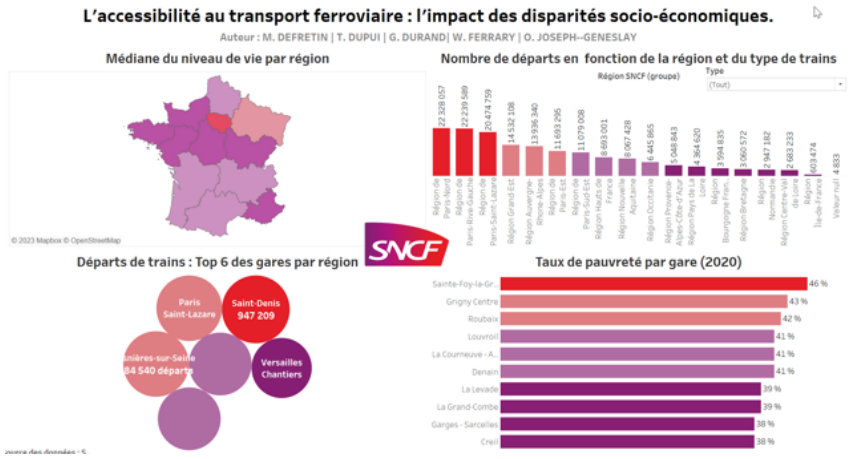

D. Conclusion & Acquis

Ce challenge, très différent des SAÉ habituelles, m'a permis de découvrir l'outil Tableau et de renforcer mes compétences en visualisation de données dans des conditions proches du monde professionnel, avec une forte contrainte de temps.

SAÉ 2-05 Construction et présentation d'indicateurs de performance

A. Présentation du projet

Ce projet de business intelligence avait pour objectif de construire et présenter une analyse de la répartition géographique et de la fortune des milliardaires en Asie en 2022, à travers un tableau de bord interactif.

B. Organisation du travail

Ce travail a été réalisé en groupe de trois étudiants. Nous avons utilisé **Tableau Desktop** pour concevoir notre dashboard. Chaque membre du groupe était responsable de produire plusieurs visualisations qui ont ensuite été intégrées dans un tableau de bord commun.

C. Démarche de résolution du problème

Notre problématique était : *« Quelle est la répartition géographique de la fortune des milliardaires en Asie ? »* Avant de créer les visuels, il a fallu explorer et comprendre le jeu de données, puis préparer les données en vérifiant le type de chaque variable. Nous avons ensuite produit plusieurs représentations : un top 10 des fortunes, une carte des fortunes par pays, l'identification de la personne la plus riche par pays, ainsi que la répartition entre fortunes héritées et fortunes construites.

D. Conclusion & Acquis

Ce projet m'a permis d'approfondir ma maîtrise de Tableau Desktop et d'appliquer les concepts de business intelligence vus en cours sur un jeu de données réel. J'ai notamment développé ma capacité à construire un dashboard cohérent et lisible à partir de plusieurs visualisations complémentaires.

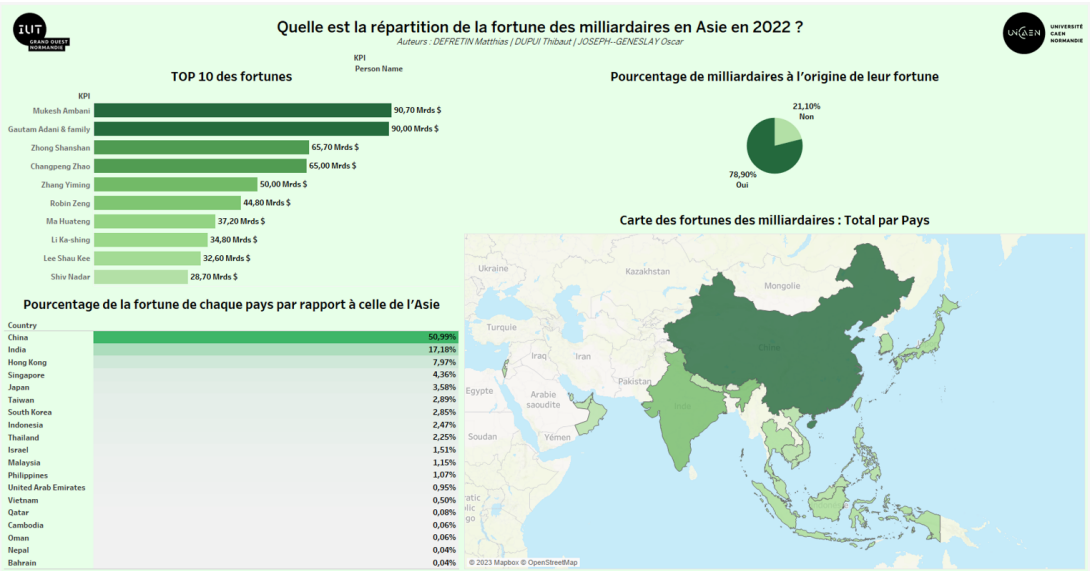

SAÉ 2-06 Analyse de données reporting et datavisualisation

EN COURS

Deuxième partie

Deuxième Année (2024-2025)

SAÉ 4.01 — Développement d'un composant d'une solution décisionnelle

A. Présentation du projet

Ce projet consistait à développer un tableau de bord interactif pour visualiser les grandes tendances économiques mondiales à partir d'indicateurs clés (PIB, espérance de vie, IDH, consommation énergétique) stockés dans une base SQLite, en exploitant HTML, CSS, JavaScript (Chart.js) et PHP natif.

B. Organisation du travail

Le développement s'est structuré en plusieurs étapes : mise en place de l'environnement (dépôt GitHub, architecture des dossiers, connexion à la base via le patron Singleton), puis développement progressif des vues et fonctions PHP en modules thématiques. Le travail collaboratif a été central : répartition des tâches, mise en commun du code via GitHub et validation mutuelle des fonctionnalités.

C. Démarche de résolution du problème

Plusieurs difficultés techniques ont été rencontrées. La connexion Singleton provoquait initialement des erreurs de requête, résolues grâce à une variable statique dans une fonction centralisée. L'affichage dynamique avec Chart.js générait des incohérences dues à la structure des données PHP, déboguées via `console.log` et `echo`. Enfin, des requêtes paramétrées ont été intégrées pour prévenir les injections SQL.

D. Conclusion & Acquis

Ce projet m'a permis de renforcer mes compétences en développement web full-stack et en gestion de base de données, tout en découvrant concrètement comment un outil décisionnel peut donner du sens à l'analyse de données.

SAÉ 4.02 — Reporting d'une analyse multivariée

A. Présentation du projet

Ce projet s'inscrit dans le cadre de l'analyse de la cohorte AGRICAN (AGRIculture et CANcers), une vaste étude épidémiologique française visant à mieux comprendre les liens entre les expositions agricoles et les risques sanitaires. L'objectif principal était de créer des profils types d'agriculteurs en fonction des activités exercées tout au long de leur carrière, puis de produire un rapport avec des visualisations claires et compréhensibles. Pour cela, des méthodes de clustering ont été appliquées à partir de variables issues d'un questionnaire, dans l'optique de mener, dans une phase ultérieure, une analyse des indicateurs de santé afin d'identifier les catégories les plus exposées aux risques de maladies.

B. Organisation du travail

Le travail s'est organisé en plusieurs étapes successives. Nous avons commencé par préparer et nettoyer les données issues du questionnaire de la cohorte AGRICAN, puis sélectionné les variables les plus pertinentes parmi les 226 disponibles, en nous concentrant sur les activités agricoles, la durée de carrière, le tabagisme et l'année de naissance. Nous avons ensuite créé des sous-cohortes pour tenir compte des différences générationnelles entre agriculteurs, notamment entre les années 1950 et 1990, avant de mettre en œuvre les analyses statistiques (ACP, clustering) pour construire des groupes homogènes.

C. Démarche de résolution du problème

Après la sélection des variables pertinentes, une analyse en composantes principales (ACP) a été menée afin de réduire la dimensionnalité des données tout en conservant l'essentiel de l'information. Les premières composantes principales ont permis de dégager les grandes tendances d'activités agricoles : grandes cultures, élevage, viticulture, etc. Un algorithme de classification ascendante hiérarchique (CAH) a ensuite été appliqué pour créer des profils agricoles distincts, dont la description a été réalisée à partir des variables initiales afin de mieux caractériser chaque groupe.

D. Conclusion & Acquis

Pour conclure, ce projet m'a permis de construire des profils agricoles cohérents à partir de données réelles et complexes. Bien que l'analyse des indicateurs de santé ne soit pas incluse dans cette phase, le travail réalisé constitue une base solide pour de futures études épidémiologiques. Il m'a également appris à produire un rapport d'analyse clair et structuré, accessible à un public non spécialisé.

Troisième partie

Troisième Année (2025-2026)

SAÉ 5.VCOD.01 — Analyse et conception d'un outil décisionnel

A. Présentation du projet

Cette SAÉ consistait à concevoir et développer de A à Z une application web décisionnelle interactive. Notre projet, **World UniRank**, analyse la performance universitaire mondiale à partir du classement *Times Higher Education* (THE) sur dix ans (2016–2025), croisé avec des indicateurs socio-économiques par pays (PIB, alphabétisation, parité, ouverture internationale), dans l'objectif de comprendre les dynamiques mondiales de l'enseignement supérieur.

B. Organisation du travail

Projet réalisé en groupe de quatre étudiants. Avant toute ligne de code, nous avons traversé une phase de conception complète : dictionnaire des concepts, modèle conceptuel (MCD) puis logique (MLD), avant d'implémenter la base SQLite via SQLAlchemy. Le développement s'est ensuite réparti entre les membres, coordonné via GitHub avec des phases régulières de merge et de validation mutuelle.

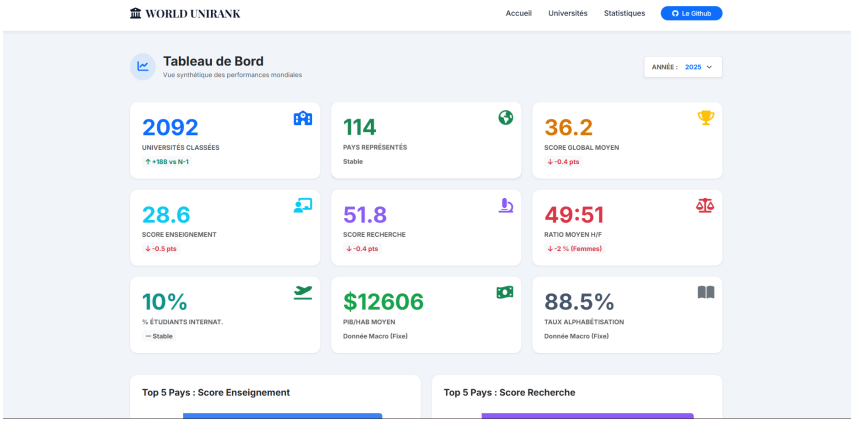

C. Démarche de résolution du problème

L'application propose quatre modules : un tableau de bord avec KPIs dynamiques, un explorateur d'universités avec recherche par pays et année, une fiche détail affichant l'évolution pluriannuelle de chaque établissement, et un module de corrélations entre indicateurs socio-économiques et qualité universitaire. La stack technique retenue était Python/Flask, Bootstrap 5, Chart.js et Pandas.

D. Conclusion & Acquis

Cette SAÉ a été la plus complète de ma formation, couvrant l'intégralité du cycle de développement : de la modélisation jusqu'au déploiement. Elle m'a permis de consolider mes compétences en développement web full-stack et de mieux appréhender l'importance des étapes de conception en amont du développement.

SAÉ 5.02 — Migration de données vers un environnement NoSQL

A. Présentation du projet

Cette SAÉ avait pour objectif de découvrir **MongoDB** en analysant un jeu de données e-commerce réel provenant d'**Olist**, une plateforme brésilienne reliant petites entreprises et clients. Le travail était double : réaliser une phase ETL pour importer des fichiers CSV dans MongoDB, puis exploiter le framework d'agrégation pour en extraire des indicateurs clés de performance.

B. Organisation du travail

Projet réalisé en binôme avec Python et `pymongo`. Pour optimiser les performances sur plus de 100 000 lignes, nous avons mis en place des index sur les champs de jointure, réduisant le temps d'exécution des agrégations de plusieurs secondes à quelques millisecondes.

C. Démarche de résolution du problème

L'analyse s'est articulée autour de quatre axes. Sur le plan commercial, nous avons étudié le positionnement prix par catégorie via les médianes pour éviter les biais liés aux valeurs aberrantes, et identifié les vendeurs les plus fiables parmi ceux ayant un volume significatif de commandes. Sur le plan logistique, nous avons mis en évidence une fracture géographique marquée : les états d'Amazonie affichent des délais frôlant 30 jours, soit trois fois la médiane nationale. Enfin, une analyse de satisfaction par catégorie a révélé que les livres obtenaient les meilleures notes, tandis que le mobilier de bureau était la catégorie la moins bien perçue.

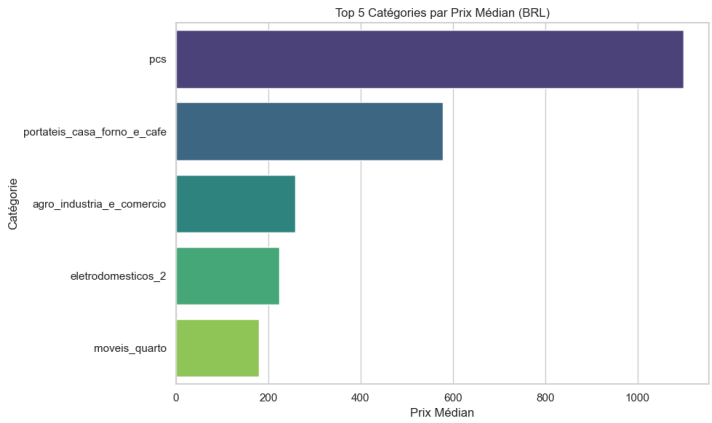

D. Conclusion & Acquis

Cette SAÉ m'a permis de découvrir le paradigme NoSQL et de comprendre en quoi il diffère des bases relationnelles classiques. Travailler sur un jeu de données aussi volumineux et réel a rendu l'analyse particulièrement concrète et formatrice.

SAÉ 5.03 — Mise en œuvre d'un processus de Data Mining

A. Présentation du projet

Cette SAÉ consistait à mettre en œuvre un processus complet de Data Mining appliqué à un cas concret : la conception d'un **système de scoring crédit** visant à automatiser la décision d'octroi de prêts bancaires. L'objectif était de prédire la probabilité qu'un client rembourse son prêt à partir de données personnelles, financières et historiques, en livrant un outil exploitable par un conseiller bancaire.

B. Organisation du travail

Projet réalisé en binôme, structuré en trois branches distinctes sur GitHub : une phase ETL, une phase de modélisation (entraînement et sélection du modèle), et une phase de déploiement via une application **Streamlit**. Cette organisation a permis de travailler en parallèle tout en assurant une intégration progressive des livrables.

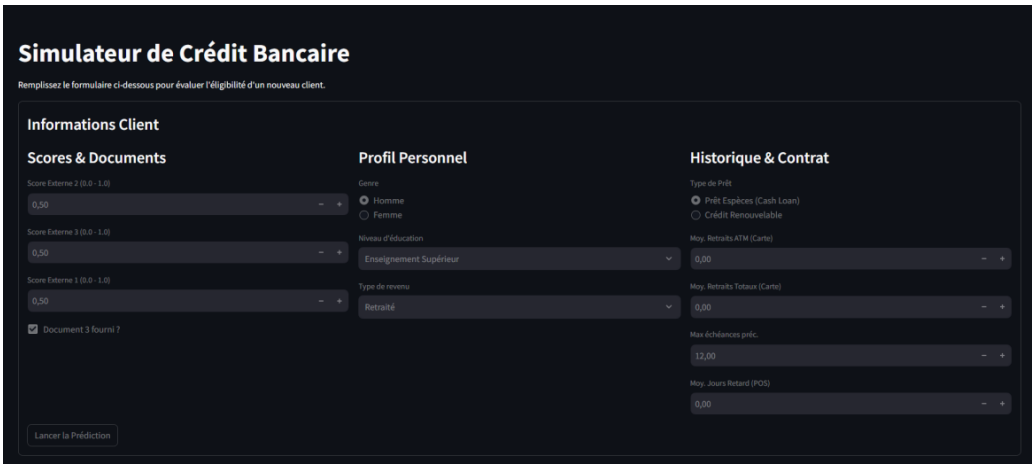

C. Démarche de résolution du problème

La phase ETL a consisté à fusionner plusieurs fichiers sources, traiter les valeurs manquantes et aberrantes, puis créer de nouvelles variables métier. Face au fort déséquilibre des classes, nous avons appliqué la technique **SMOTE**. Plusieurs algorithmes ont été comparés (Régression Logistique, Random Forest, XGBoost) et le modèle XGBoost a obtenu les meilleures performances en AUC. Pour rendre l'application utilisable, nous avons réduit le modèle aux 15 variables les plus influentes, conciliant ainsi performance prédictive et facilité de saisie.

D. Conclusion & Acquis

Pour conclure, ce projet m'a permis de mettre en œuvre l'entrainement et l'usage d'un modèle tel que XGBoost ce qui a rendu ce projet très intéressant car cela m'a permis de mettre un pied dans le machine learning.

SAÉ 6.VCOD.01 - Développement et test d'un outil décisionnel

EN COURS